

## Examen de Régression Linéaire GIS2A-4

(cours de C. Preda)

Temps de travail : 2h  
Tous documents autorisés.

### Exercice 1. (9p)

Un modèle de régression linéaire multiple de la forme suivante a été ajusté sur un jeu de données :

$$Y_i = \beta_0 + \beta_1 \cdot x_{i,1} + \beta_2 \cdot x_{i,2} + \beta_3 \cdot x_{i,3} + \beta_4 \cdot x_{i,4} + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2)$$

Avec le logiciel R on obtient la sortie suivante :

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	???	0.1960	8.438	3.57e-13
x1	5.3036	2.5316	???	0.038834
x2	4.0336	2.4796	1.627	0.107111
x3	-9.3153	2.4657	-3.778	0.000276
x4	0.5884	2.2852	0.257	0.797373

Residual standard error: 1.892 on 95 degrees of freedom



Multiple R-squared: 0.1948, Adjusted R-squared: ???

F-statistic: 5.745 on 4 and 95 DF, p-value: 0.0003483

On demande :

- Combien d'observations ont été utilisées pour estimer le modèle ?
- Quelle est la valeur de l'estimation de  $\beta_0$  et de la statistique de test pour vérifier l'hypothèse  $\beta_1 = 0$ .
- Avec un risque d'erreur de 5%, peut-on rejeter l'hypothèse selon laquelle la variable X3 n'influence pas Y dans ce modèle ?
- Quelle est l'estimation de la variance de  $\varepsilon$  ?
- Quelle est votre interprétation pour le coefficient de la variable X3 ?
- Que représente R2 ici ? Calculer aussi R2-ajusté et expliquer son utilité.
- Quelle hypothèse nulle est associée à la statistique de test de Fisher *F-statistic* ?
- Quelle est la prédiction faite par le modèle pour  $x_1 = 2$ ,  $x_2 = 1$ ,  $x_3 = 4$  et  $x_4 = 0$  ? Que représente cette prédiction ?

9) Voici le graphique des résidus :



Le test de normalité de Shapiro Wilks nous donne une p-valeur égale à 0.002 et le test de homoscedasticité de Pagan p-valeur < 0.001.

Que pouvez vous commenter quant aux conditions d'applications du modèle ?

**Exercice 2 (6p).**

Soit  $X_1$  et  $X_2$  deux variables quantitatives qui représentent les observations d'une même variable aléatoire  $X$  par deux observateurs différents. On utilise le modèle de régression

$$X_2 = \beta X_1 + \varepsilon, \varepsilon \sim \Omega(0, \sigma^2) \text{ indépendant de } X_1$$

notamment pour vérifier l'hypothèse selon laquelle les deux observateurs mesurent la même chose (mesures concordantes).

On demande :

- 1) Quelle est l'estimateur de moindres carrés de  $\beta$  ?
- 2) Proposez un estimateur pour  $\sigma^2$ .
- 3) Quelle est la statistique de test utilisée pour vérifier l'hypothèse selon laquelle les deux observateurs concordent ?
- 4) Pour  $\beta = 1$  tracez la droite de régression.

**Exercice 3 (5p).** Dans un échantillon aléatoire de 100 sujets choisis dans une population en surcharge pondérale, on étudie la relation entre le tour de taille en centimètres et la glycémie à jeun.

On obtient les valeurs suivantes :

Tour de Taille :  $TT = 91 \pm 14$  (Moyenne  $\pm$  écart-type)

Glycémie :  $G = 1.10 \pm 0.15$  (Moyenne  $\pm$  écart-type)

La covariance entre TT et G a été calculée :  $\text{Cov}(TT, G) = 0.84$ .

- a) Donner un intervalle de confiance de niveau 95% pour la moyenne du tour de taille dans la population étudiée.
- b) Tracer sur un graphe la droite de régression linéaire expliquant le TT en fonction de G.
- c) Quelle est la qualité du modèle linéaire ?
- d) On observe un individu dont la glycémie à jeun vaut 1.1. Quelle est la valeur prédite par le modèle linéaire pour le tour de taille de cet individu ?