

Régression Linéaire

- La régression simple

$$Y, X : \Omega \rightarrow \mathbb{R}$$

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

- La régression multiple

$$Y, \underbrace{X_1, X_2, \dots, X_p}_p$$

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$$

But :

- estimation de $\{\beta_i\}_{i \geq 0}$


- qualité du modèle

La régression simple

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Pour $X = x$ fixe

$$\left\{ \begin{array}{l} Y | X=x = \beta_0 + \beta_1 x + \varepsilon \\ E(\varepsilon) = 0 \\ \text{Var}(\varepsilon) = \sigma^2 \\ E(Y | X=x) = \beta_0 + \beta_1 x \end{array} \right.$$



Notons par $\hat{y} = \beta_0 + \beta_1 x$

Alors $y = \underbrace{\hat{y}}_{\text{modèle}} + \underbrace{\varepsilon}_{\text{aléa}}$

Estimation de $\beta_0, \beta_1, \sigma^2$


$(y_1, x_1), \dots, (y_n, x_n), n \geq 1$

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_1 + \varepsilon_1 \\ y_2 = \beta_0 + \beta_1 x_2 + \varepsilon_2 \\ \vdots \\ y_n = \beta_0 + \beta_1 x_n + \varepsilon_n \end{cases}$$

Moindres carrés :

chercher β_0, β_1 t.q.:

$$L(\beta_0, \beta_1) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



$$\frac{\partial L}{\partial \beta_0} = 0 \quad \frac{\partial L}{\partial \beta_1} = 0$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\text{ave } \begin{cases} \bar{y} = \frac{1}{n} \sum y_i \\ \bar{x} = \frac{1}{n} \sum x_i \end{cases}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\sigma}^2 = \frac{1}{n-2} \sum_{i=1}^n e_i^2$$

Th.: $\hat{\beta}_0, \hat{\beta}_1$ et $\hat{\sigma}^2$ sont estimateurs
sans biais de $\beta_0, \beta_1, \sigma^2$.

$$\begin{cases} E(\hat{\beta}_0) = \beta_0 \\ \text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \end{cases}$$

$$\begin{cases} E(\hat{\beta}_1) = \beta_1 \\ \text{Var}(\hat{\beta}_1) = \sigma^2 \left(\frac{1}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \end{cases}$$

Remarque

Soit $\Delta_y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$

$$\Delta_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\Delta_e^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum_{i=1}^n e_i^2$$

$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\frac{1}{n} \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\text{cov}(x, y)}{\Delta_x \cdot \Delta_y}$$

$$\sigma_e^2 = (1 - R^2) \sigma_y^2$$

ou

$$\underbrace{\sigma_y^2}_{\text{var totales}} = \underbrace{\sigma_e^2}_{\text{var résiduelle}} + \underbrace{R^2 \sigma_y^2}_{\text{variance expliquée par le modèle :}}$$

On a également :

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2} = \underbrace{\sum_{i=1}^n (y_i - \hat{y}_i)^2} + \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}$$

Inference

$$\frac{\hat{\beta}_1 - \beta_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim T_{n-2}$$

$$\frac{\hat{\beta}_0 - \beta_0}{\sqrt{\text{Var}(\hat{\beta}_0)}} \sim T_{n-2}$$

Rem: Si $\rho = \frac{\text{Cor}(x, y)}{\sqrt{V(x) \cdot V(y)}} = 0$ alors $\beta_1 = 0$

$$\frac{\hat{\beta}_1}{\sqrt{\text{Var}(\hat{\beta}_1)}} \sim T_{n-2}$$

$$\Downarrow$$
$$\left[\frac{r}{\sqrt{1-r^2}} \sqrt{n-2} \sim T_{n-2} \right]$$

Test pour $r=0$!

Tests dans le modèle linéaire


$$\begin{cases} H_0 : \beta_1 = 0 \\ H_1 : \beta_1 \neq 0 \end{cases}$$

- à l'aide de Student

- utilisant la décomposition de la variance :

$$\frac{1}{\sigma^2} \times \left| \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 \right.$$

\downarrow χ^2_{n-1} \downarrow si $\beta_1 = 0$ χ^2 \downarrow χ^2_{n-2}



$$\frac{\sum_i (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \hat{y}_i)^2} (n-2) \sim F(1, n-2)$$

$\beta_1 = 0$

$$\parallel$$
$$\frac{R^2}{1-R^2} (n-2)$$

Etude des résidus

$$e_1, e_2, \dots, e_n$$

$$e_1 + e_2 + \dots + e_n = 0 \quad (\text{pas d'indépendance})$$

On teste généralement une tendance ou une dépendance entre $\underline{e_i}$ et $\underline{e_{i+n}}$

Test de Durbin-Watson :

$$\begin{cases} H_0 : \text{il n'y a pas de corrélation entre } \varepsilon_i \text{ et } \varepsilon_{i+n} \\ H_1 : \varepsilon_{i+n} = \rho \varepsilon_i + u_i \end{cases}$$

Statistique de test :

$$d = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

\approx près de $\underline{2}$
 H_0



table statistique.

On vérifie que $0 \leq d \leq 4$

Prévision

Soit $X = x_0$.

Alors

$$\hat{y}_0 = \beta_0 + \beta_1 x_0$$

$$\text{Var}(\hat{y}_0) = \sigma^2 \left(\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right) \quad (\text{Démon.}).$$

Mais y_0 et \hat{y}_0 sont indépendantes !

$\Rightarrow y_0 - \hat{y}_0 :$

$$\underbrace{\text{var}(y_0 - \hat{y}_0)}_{\varepsilon} = \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right)$$

$$\boxed{\frac{y_0 - \hat{y}_0}{\sigma \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_i (x_i - \bar{x})^2}}} \sim T_{n-2}}$$

IC¹⁺(y_0) : \nearrow grand si $|x_0 - \bar{x}|$ grand.